Trabalho Prático — Fase 1

Coleta e Análise Exploratória de Dados Bibliográficos via Web Scraping

Books to Scrape

Marcelo Ferreira Miranda
Fatec Araras — Desenvolvimento de Software Multiplataforma
Mineração de Dados | Abril 2026

Contexto e objetivos

O que é KDD?

Knowledge Discovery in Databases — processo estruturado para extrair conhecimento útil de dados brutos (Fayyad et al., 1996).

Etapas: Seleção → Pré-processamento → Transformação → Mineração → Interpretação

Este trabalho cobre as 3 primeiras etapas.

Objetivo do trabalho

Implementar pipeline ETL completo de web scraping sobre o repositório Books to Scrape:

- Coleta de 1.000 registros de livros
- Limpeza e pré-processamento
- Análise exploratória inicial
- Base pronta para mineração nas próximas fases

POR QUE BOOKS TO SCRAPE?

Educacional

Criado para fins de prática — sem restrições no robots.txt

HTML consistente

Estrutura bem organizada, reduz complexidade de extração

Mix de atributos

Numéricos (preço, rating) + categóricos (gênero, estoque)

Ética garantida

Termos de uso autorizam uso para aprendizado

Pipeline ETL implementado

1. Extração

Requests + BeautifulSoup
50 páginas de listagem
1.000 páginas de detalhe
User-Agent personalizado
Pausa 0,1s/requisição

→

2. Transformação

Parsing HTML → campos
Regex para remover £
Rating texto → int
ex: 'Three' → 3
Verificação de tipos

→

3. Pré-processamento

Checagem de nulos: 0
Deduplicação UPC: 0
Outliers IQR: 0
Categorias suspeitas identificadas

→

4. Carga

books_raw.csv (8 cols)
books_clean.csv (10 cols)
1.000 registros × 10 atributos por instância
Pandas DataFrame

DIFERENCIAIS TÉCNICOS DE RESILIÊNCIA

- Retry automático: até 5 tentativas por URL com backoff progressivo
- Checkpoint JSON: salva progresso a cada página — retomada sem perda de dados
- Deduplicação em tempo real: controle de UPCs durante a coleta (set em memória)

Dataset: atributos e métricas gerais

1.000	10	0	50
registros coletados	atributos finais	nulos / duplicatas	categorias literárias

ATRIBUTOS DO DATASET

Atributo	Tipo	Descrição	Origem
title	Texto	Título do livro	Scraping
category	Categ.	Gênero literário (50 valores)	Scraping
rating	Int 1–5	Avaliação em estrelas	Scraping
price_gbp	Float £	Preço sem imposto	Scraping
price_incl_tax	Float £	Preço com imposto (idêntico)	Scraping
stock_quantity	Int	Quantidade em estoque (1–22)	Scraping
in_stock	Categ.	Disponibilidade: Yes / No	Scraping
upc	ID único	Código identificador do produto	Scraping
price_range ★	Categ.	Barato / Médio / Caro	Derivado ETL
rating_label ★	Categ.	Péssimo / Ruim / Regular / Bom / Excelente	Derivado ETL

Qualidade da base e estatísticas descritivas

DIAGNÓSTICO DE QUALIDADE — RESULTADOS

0
Valores nulos
em todas as 8 colunas originais

0
Duplicatas (UPC)
dos 1.000 UPCs são únicos

0
Outliers de preço
faixa IQR: £−15,92 até £85,48

0
Outliers esperados
todos os preços: £10,00 – £59,99

ESTATÍSTICAS DESCRITIVAS — VARIÁVEIS NUMÉRICAS

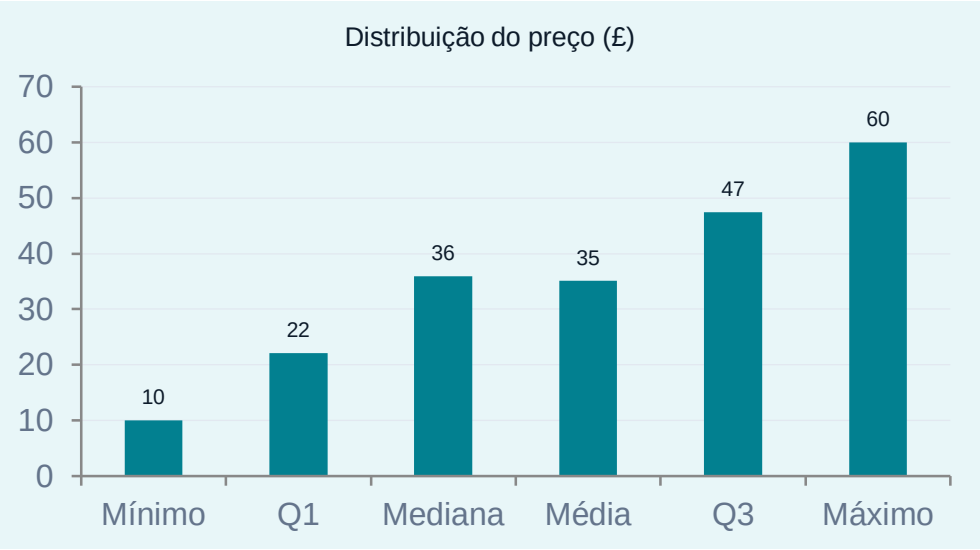

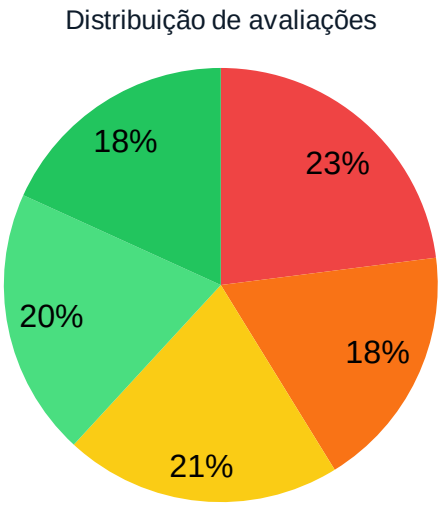

Distribuição das variáveis categóricas

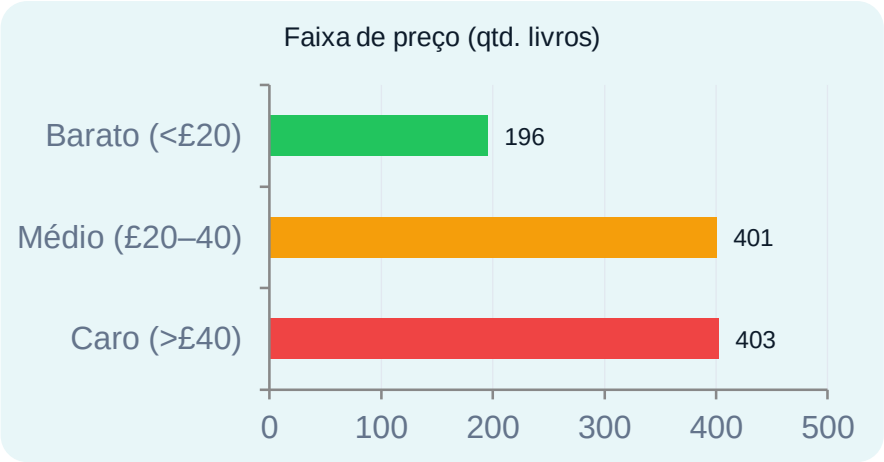

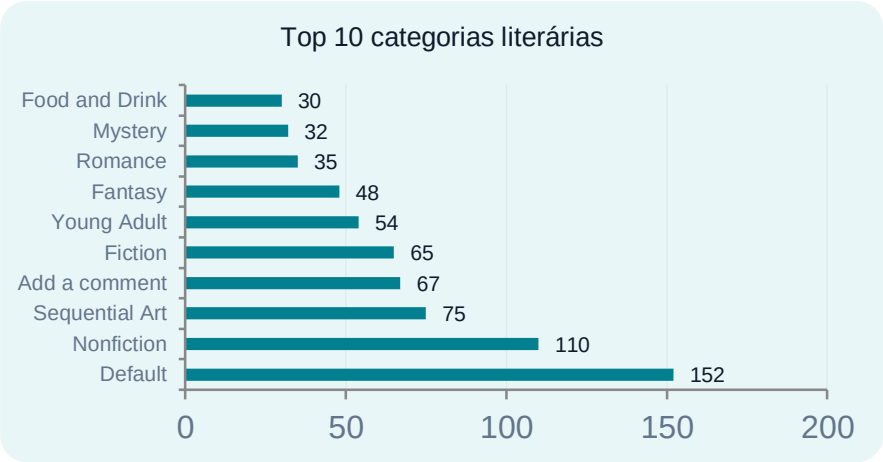

PONTOS DE ATENÇÃO IDENTIFICADOS

Categoria "Default" (152 registros — 15,2%): agrupa livros sem categorização específica no site. Pode ser filtrada ou tratada nas próximas fases.

Categoria "Add a comment" (67 registros — 6,7%): provavelmente artefato de scraping, capturando elemento de interface do HTML. Recomenda-se exclusão ou reclassificação antes da mineração.

Resultados da limpeza e posicionamento no KDD

COMPARATIVO ANTES/DEPOIS DO PRÉ-PROCESSAMENTO

Métrica	Antes	Depois	Observação
Total de registros	1.000	1.000	Nenhum registro removido
Valores nulos	0	0	Fonte já era limpa (dados simulados)
Duplicatas	0	0	Confirmado por unicidade dos UPCs
Outliers de preço	0	0	Faixa IQR: £−15,92 a £85,48
Nº de atributos	8	**10**	**+ price_range e rating_label (derivados)**

ETAPAS DO PROCESSO KDD — ONDE ESTAMOS

1. Seleção	2. Pré-processamento	3. Transformação	4. Mineração	5. Interpretação
Fase 1 ✓	Fase 1 ✓	Fase 1 ✓	Próximas fases	Próximas fases

PRÓXIMOS PASSOS PREVISTOS

Classificação supervisionada — prever faixa de preço ou rating | **Agrupamento (clustering)** — segmentação de perfis | **Regras de associação** — relações entre categoria e preço | **Dashboard final** da disciplina

Conclusão

O que foi entregue nesta fase

Pipeline ETL completo

Scraper funcional com retry, checkpoint e coleta em dois níveis.

Base de qualidade

1.000 registros, 10 atributos, zero nulos e zero duplicatas.

Enriquecimento

Variáveis derivadas price_range e rating_label criadas.

Problemas mapeados

Categorias 'Default' e 'Add a comment' identificadas para tratamento.

Base para mineração

Dataset pronto para classificação, clustering e regras de associação.