Coleta e Análise Exploratória de Dados Bibliográficos via Web Scraping no Repositório Books to Scrape

Marcelo Ferreira Miranda

Fatec Araras — Desenvolvimento de Software Multiplataforma

marcelo.miranda2@fatec.sp.gov.br

Abstract

Este trabalho descreve o processo de coleta e pré-processamento de dados bibliográficos como primeira etapa do processo KDD (Knowledge Discovery in Databases). Utilizando Python com as bibliotecas Requests e BeautifulSoup, foi implementado um script de web scraping para coleta de 1.000 registros de livros do repositório público Books to Scrape. O pipeline ETL desenvolvido contempla extração via raspagem de HTML, transformações para normalização e estruturação dos dados, e carga em formato CSV. A base resultante possui 10 atributos por instância, sendo 4 numéricos (avaliação, preço sem imposto, preço com imposto e quantidade em estoque) e 4 categóricos (gênero literário, disponibilidade, faixa de preço e rótulo de avaliação). A análise de qualidade não identificou valores ausentes ou duplicatas na base coletada, e foram aplicadas transformações de enriquecimento para geração de variáveis derivadas. Os dados obtidos constituem fundação para as etapas seguintes de mineração, incluindo classificação, agrupamento e análise de associação.

Keywords

Web scraping, KDD, ETL, pré-processamento, Python, BeautifulSoup, mineração de dados.

I. INTRODUÇÃO

Com o avanço da internet, grandes volumes de dados estruturados passaram a estar disponíveis publicamente em páginas web. A extração automatizada desses dados, conhecida como web scraping, tornou-se uma alternativa viável para construção de bases de dados em cenários onde APIs oficiais não estão disponíveis ou são limitadas [1].

O domínio bibliográfico foi escolhido por apresentar características interessantes para mineração de dados: atributos numéricos como preço e avaliação coexistem com atributos categóricos como gênero literário, permitindo investigar relações como "livros de determinados gêneros tendem a custar mais?" ou "existe correlação entre preço e avaliação dos usuários?".

O site Books to Scrape foi selecionado como fonte de dados por ser um repositório desenvolvido especificamente para fins educacionais, sem restrições no arquivo robots.txt e com estrutura HTML consistente e bem organizada, o que reduz significativamente a complexidade do processo de extração [2].

Os objetivos deste trabalho são: implementar um script funcional de web scraping; aplicar o pipeline ETL sobre os dados coletados; realizar análise exploratória inicial; e posicionar o trabalho no contexto do processo KDD como preparação para as próximas fases da disciplina.

II. FUNDAMENTAÇÃO TEÓRICA

A. KDD — Knowledge Discovery in Databases

O processo KDD foi formalizado por Fayyad et al. [3] como uma sequência de etapas para extração de conhecimento útil a partir de dados brutos. As etapas compreendem: seleção e coleta dos dados, pré-processamento e limpeza, transformação, mineração propriamente dita, e interpretação dos resultados. O presente trabalho cobre as três primeiras etapas, estabelecendo a base para as minerações que virão nas próximas fases da disciplina.

B. Web Scraping

Web scraping é a extração automatizada de dados de páginas web por meio de análise do código HTML [4]. O processo envolve tipicamente: realizar uma requisição HTTP para obter o código da página; analisar a estrutura HTML para localizar os elementos de interesse; e extrair e estruturar as informações desejadas. As principais ferramentas Python para esse fim são Requests, para requisições HTTP, e BeautifulSoup, para parsing do HTML.

C. ETL

ETL (Extract, Transform, Load) é o processo de mover dados de uma fonte bruta para um repositório analítico estruturado, passando por transformações intermediárias [5]. No contexto de web scraping, a extração é o próprio scraping, a transformação envolve limpeza e normalização dos campos, e a carga resulta em um arquivo CSV ou banco de dados pronto para análise.

D. Pré-processamento de Dados

O pré-processamento é uma das etapas mais críticas do KDD, pois a qualidade dos dados impacta diretamente os resultados da mineração [1]. As principais tarefas incluem identificação e tratamento de valores ausentes, remoção de duplicatas, detecção de outliers e transformações como normalização e codificação de variáveis categóricas.

III. METODOLOGIA

A. Fonte de Dados e Considerações Éticas

O repositório Books to Scrape (books.toscrape.com) contém 1.000 livros fictícios distribuídos em 50 páginas, com 20 itens por página. Cada livro possui uma página de detalhes com informações complementares. O arquivo robots.txt do site não impõe restrições de acesso, e os termos de uso autorizam explicitamente o uso do site para fins de

prática e aprendizado [2]. Para evitar sobrecarga no servidor, foi implementada uma pausa de 0,1 segundo entre requisições consecutivas.

B. Implementação do Scraper

O script foi desenvolvido em Python 3.12 com as seguintes bibliotecas: Requests 2.31 para requisições HTTP; BeautifulSoup 4.12 com parser nativo html.parser para navegação na árvore DOM; Pandas 2.1 para estruturação e exportação dos dados; e os módulos nativos re, os, json e time para expressões regulares e controle de fluxo.

A coleta funciona em dois níveis: primeiro percorre as 50 páginas de listagem para obter URLs dos livros, e em seguida acessa a página de detalhes de cada livro individualmente para extrair atributos complementares como categoria, UPC e quantidade em estoque. Para lidar com instabilidades de rede, foi implementado um mecanismo de retry com até 5 tentativas por URL e backoff progressivo, além de salvamento de checkpoint em JSON a cada página concluída, permitindo retomada da coleta em caso de falha.

C. Pipeline ETL e Diagrama de Fluxo

O pipeline ETL foi estruturado em quatro etapas sequenciais, conforme ilustrado:

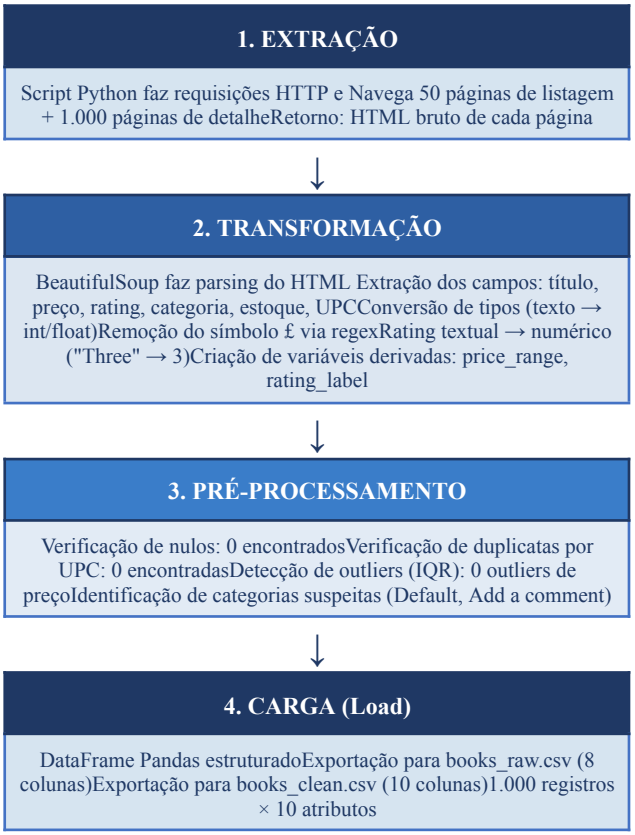

Figura 1 — Diagrama do Pipeline ETL implementado

D. Campos Coletados

Campo	Tipo	Descrição
title	Texto	Título do livro
category	Categórico	Gênero literário (50 valores)
rating	Numérico int.	Avaliação de 1 a 5 estrelas
price_gbp	Numérico float	Preço sem imposto em libras
price_incl_tax	Numérico float	Preço com imposto em libras
stock_quantity	Numérico int.	Quantidade disponível em estoque
in_stock	Categórico	Disponibilidade: Yes / No
upc	Texto (ID)	Código identificador único do produto
price_range*	Categórico	Faixa: Barato / Médio / Caro
rating_label*	Categórico	Rótulo textual da avaliação

Tabela I — Atributos do dataset (campos derivados criados no ETL)*

IV. RESULTADOS

A. Qualidade da Base Coletada

A análise de qualidade realizada na etapa de diagnóstico não identificou problemas graves na base. Os resultados foram: zero valores nulos em todas as 8 colunas originais; zero duplicatas, confirmado pela unicidade dos 1.000 UPCs coletados; e zero outliers de preço pelo método IQR, com limites calculados de £-15,92 a £85,48, dentro dos quais se enquadram todos os valores observados (£10,00 a £59,99).

A ausência de problemas expressivos é coerente com a natureza do site, que foi construído com dados simulados e estrutura consistente.

B. Estatísticas Descritivas

Campo	Média	Mediana	Mín.	Máx.	DP
rating	2,92	3,00	1	5	1,43
price_gbp (£)	35,07	35,98	10,00	59,99	14,45
price_incl_tax (£)	35,07	35,98	10,00	59,99	14,45
stock_quantity	8,59	7,00	1	22	5,65

Tabela II — Estatísticas descritivas das variáveis numéricas (DP = desvio padrão)

Os preços apresentam distribuição relativamente uniforme ao longo da faixa £10–£59,99, com média (£35,07) e mediana (£35,98) próximas, indicando ausência de assimetria relevante. O fato de price_gbp e price_incl_tax apresentarem valores idênticos indica que o site não aplica imposto diferenciado para nenhum item da base. O stock_quantity varia de 1 a 22 unidades, com média de 8,59 e desvio padrão de 5,65, sugerindo variabilidade moderada no estoque.

C. Distribuição das Variáveis Categóricas

Faixa de Preço	Qtd.	%
Caro (> £40)	403	40,3%
Médio (£20–£40)	401	40,1%
Barato (< £20)	196	19,6%

Tabela III — Distribuição por faixa de preço

Avaliação	Qtd.	%
Péssimo (1)	226	22,6%
Ruim(2)	179	17,9%
Regular(3)	203	20,3
Bom(4)	179	17,9%
Excelente (5)	196	19,6%

Tabela IV — Distribuição por avaliação

Categoria (Top 10)	Qtd.	%
Default	152	15,2%
Nonfiction	110	11,0%
Sequential Art	75	7,5%
Add a comment	67	6,7%
Fiction	65	6,5%
Young Adult	54	5,4%
Fantasy	48	4,8%
Romance	35	3,5%
Mystery	32	3,2%
Food and Drink	30	3,0%

Tabela V — Top 10 categorias literárias por frequência

Observa-se que a categoria "Default" agrupa 152 livros sem categorização específica no site.; A categoria "Add a comment" (67 registros) é aparentemente um artefato do scraping, possivelmente captando um elemento de interface do site. Ambas as categorias deveriam ser tratadas para melhor consistência de dados

D. Amostra e Panorama Final da Base

Título	Categoria	Rating	£ s/imp.	Estoque
A Light in the Attic	Poetry	3	51,77	22
Tipping the Velvet	Hist. Fiction	1	53,74	20
Soumission	Fiction	1	50,10	20
Sharp Objects	Mystery	4	47,82	20
Sapiens	History	5	54,23	20

Tabela VI — Amostra das primeiras linhas do dataset final

E. Comparativo Antes/Depois da Limpeza

Métrica	Antes	Depois
Total de registros	1.000	1.000
Valores nulos	0	0
Linhas duplicadas	0	0
Outliers de preço	0	0
Nº de atributos	8	10

Tabela VII — Comparativo antes/depois do pré-processamento

Embora a limpeza não tenha removido registros — dado que a fonte já era limpa — o processo foi igualmente importante para confirmar a integridade da base e aplicar as transformações de enriquecimento. A base cresceu de 8 para 10 atributos com a adição de price_range e rating_label, ampliando as possibilidades analíticas nas fases seguintes.

F. Posicionamento no Processo KDD

O trabalho atual cobre as três primeiras etapas do KDD: (1) Seleção — definição da fonte e dos atributos de interesse; (2) Pré-processamento — diagnóstico e limpeza da base; (3) Transformação — normalização, tipagem e enriquecimento com variáveis derivadas. As etapas seguintes — mineração propriamente dita e interpretação dos resultados — serão realizadas nas próximas fases da disciplina, com aplicação de algoritmos de classificação, agrupamento e análise de associação sobre esta mesma base.

V. CONCLUSÃO

Este trabalho implementou uma pipeline completa de coleta e pré-processamento de dados bibliográficos, abrangendo as etapas iniciais do processo KDD. O script de web scraping desenvolvido coletou os 1.000 registros esperados do repositório Books to Scrape, com 10 atributos por instância, respeitando as diretrizes éticas do site.

A base obtida apresentou qualidade elevada desde a coleta, sem valores ausentes ou duplicatas, o que permitiu focar o trabalho de pré-processamento nas transformações de enriquecimento. Duas categorias merecem atenção nas próximas etapas: "Default" (152 registros sem categorização) e "Add a comment" (67 registros possivelmente oriundos de artefato de scraping), que poderão ser filtrados ou reclassificados.

A principal dificuldade enfrentada foi a instabilidade de conexão com o servidor durante a coleta, que exigiu a implementação de mecanismos de retry e checkpoint para garantir a completude da base sem perda de dados já coletados. Como próximos passos, a base será utilizada para classificação supervisionada, agrupamento por perfil de livro e análise de associação entre categorias e faixas de preço, culminando na construção do dashboard final da disciplina.

REFERÊNCIAS

[1] U. Fayyad, G. Piatetsky-Shapiro e P. Smyth, "From Data Mining to Knowledge Discovery in Databases," AI Magazine, vol. 17, n. 3, pp. 37–54, 1996.

[2] Books to Scrape, "A Fictional Bookstore for Scraping Practice," [Online]. Disponível em: https://books.toscrape.com. Acesso em: abr. 2026.

[3] I. H. Witten, E. Frank e M. A. Hall, Data Mining: Practical Machine Learning Tools and Techniques, 3. ed. Burlington: Morgan Kaufmann, 2011.

[4] R. Mitchell, Web Scraping with Python, 2. ed. Sebastopol: O'Reilly Media, 2018.

[5] R. Kimball e J. Caserta, The Data Warehouse ETL Toolkit. Indianapolis: Wiley, 2004.

[6] Python Software Foundation, "Python 3.12 Documentation," [Online]. Disponível em: https://docs.python.org/3/. Acesso em: abr. 2026.

[7] L. Richardson, "Beautiful Soup Documentation," [Online]. Disponível em: https://www.crummy.com/software/BeautifulSoup/. Acesso em: abr. 2026.

[8] W. McKinney, Python for Data Analysis, 3. ed. Sebastopol: O'Reilly Media, 2022.